

Predicción Probabilística de Posiciones en Teamfight Tactics: Un Enfoque Bayesiano No Paramétrico con BART

Alain Phillip Jay

Ingeniería Matemática, Universidad EAFIT

Medellín, Colombia

ajayr@eafit.edu.co

23 de junio de 2026

Resumen

El presente trabajo tiene como objetivo predecir probabilidades dinámicas de supervivencia y desempeño relativo en el videojuego competitivo Teamfight Tactics (TFT) a partir del historial reciente de los jugadores y del contexto competitivo del lobby. Para ello, formulamos el problema bajo un enfoque de análisis de supervivencia discreto, donde el tiempo se mide mediante la ronda final alcanzada por cada jugador. Para superar las limitaciones de los modelos de riesgos proporcionales paramétricos, implementamos un enfoque bayesiano no paramétrico utilizando Bayesian Additive Regression Trees (BART). Mediante la expansión longitudinal de los datos y el uso de variables latentes con enlace Probit, el modelo estima las probabilidades de eliminación capturando de manera implícita interacciones complejas en el juego.

1. Introducción

El análisis de supervivencia tradicionalmente aborda el tiempo hasta la ocurrencia de un evento, modelando la función de riesgo y la probabilidad de supervivencia $S(t)$. En el contexto del videojuego Teamfight Tactics (TFT), donde ocho jugadores compiten hasta que sus puntos de vida llegan a cero, la duración de la partida puede formularse naturalmente como un tiempo de supervivencia. Específicamente, la escala de tiempo discreto en este trabajo se define utilizando la ronda final alcanzada por cada jugador antes de ser eliminado. Históricamente, los enfoques semiparamétricos como el modelo de riesgos proporcionales de Cox han sido dominantes para relacionar covariables con el tiempo de supervivencia. Sin embargo, en la práctica, las variables de interés suelen exhibir efectos

Este proyecto fue desarrollado bajo la política “Legal Jibber Jabber” de Riot Games utilizando activos de su propiedad. Riot Games no respalda ni patrocina este proyecto. *Teamfight Tactics* y *Riot Games* son marcas registradas de Riot Games, Inc.

no proporcionales y relaciones altamente no lineales. Modelos recientes basados en ensambles de árboles de regresión, en particular BART (Bayesian Additive Regression Trees), ofrecen un marco de trabajo sumamente flexible que supera a competidores tradicionales sin imponer formas funcionales restrictivas y provee una cuantificación natural de la incertidumbre. Este proyecto aplica dicha metodología con el objetivo de predecir probabilidades dinámicas de supervivencia y desempeño relativo en TFT a partir del historial reciente de los jugadores y del contexto competitivo del lobby. De este modo, el modelo no utiliza información de la partida objetivo como predictor, sino que basa sus estimaciones únicamente en información histórica previa a la partida y en las características relativas de los oponentes.

2. Metodología

2.1. Construcción del Dataset Empírico y Filtros

La base de datos empírica se construyó mediante la extracción de historiales de partidas utilizando la API de Riot Games, resolviendo las identidades de los jugadores a través de su PUUID. Para asegurar la homogeneidad y madurez competitiva de los datos, la cohorte analítica se restringió a partidas clasificatorias estándar jugadas en los parches recientes 16.4, 16.5 y 16.6. Se aplicaron filtros analíticos que excluyeron partidas atípicas o de abandono temprano, requiriendo que los jugadores alcanzaran como mínimo el nivel 4 y sobrevivieran más allá de la ronda 18.

Un elemento central del diseño metodológico fue la aplicación de un período de **burn-in** por jugador: las primeras 10 partidas observadas de cada sujeto se utilizaron exclusivamente para construir su historial estadístico y estabilizar sus métricas previas, pero no se incluyeron como observaciones objetivo (target) en el entrenamiento del modelo.

2.2. Estructura de los Datos y Tiempo de Supervivencia

Para implementar el algoritmo BART en un problema de supervivencia, transformamos el enfoque a uno de clasificación binaria secuencial sobre un tiempo discreto. En esta aplicación empírica, la escala de tiempo se operacionaliza estrictamente mediante la ronda final alcanzada por el jugador. Aunque la duración de la partida puede agruparse en fases, estas se utilizan únicamente como variables descriptivas o covariables auxiliares, ya que modelar directamente sobre la ronda conserva una mayor resolución temporal.

Cada registro se expande longitudinalmente sobre esta grilla de rondas. El evento de eliminación (**status** = 1) se asigna a los jugadores que finalizan entre el 2.º y el 8.º lugar, mientras que el ganador experimenta censura por la derecha (**status** = 0), finalizando su participación con una secuencia exclusiva de ceros.

2.3. Covariables Históricas, Contexto de Lobby y Suavizado

El vector de características x_i que alimenta al modelo omite cualquier información observada durante la partida objetivo, garantizando que **las predicciones se basen exclusivamente en información previa**. Las covariables construidas se dividen en dos categorías principales:

- **Atributos históricos del jugador:** Calculados únicamente con el pasado disponible hasta el match actual. Incluyen la cantidad de partidas previas (experiencia), y medias históricas de posición (`placement`), ronda final, proporción de Top 4, proporción de victorias (`win_rate`), nivel final y oro remanente. Para evitar estimaciones inestables en jugadores con historiales cortos, estas métricas fueron estabilizadas mediante un suavizado empírico-bayesiano, acercando los promedios individuales hacia el promedio global. También se incluyeron las desviaciones estándar históricas para capturar la consistencia del jugador.
- **Atributos relativos al lobby:** Se reconstruyó el contexto competitivo del enfrentamiento incorporando métricas relativas frente a los oponentes disponibles. Estas covariables evalúan la fortaleza relativa e incluyen ventajas directas frente al lobby (ej. `placement_adv_vs_lobby`, `survival_adv_vs_lobby`), consistencia relativa, rankings históricos dentro del lobby y el conteo de oponentes empíricamente más fuertes.

2.4. Modelo Probit y Variables Latentes

Para conectar la secuencia discreta de ceros y unos con el modelo continuo de regresión de BART, recurrimos a la metodología de aumento de datos de Albert y Chib. Introducimos una variable latente continua inobservable $z_{ij} \sim N(\mu_{ij}, 1)$, la cual condicionamos según los datos observados: se trunca en el intervalo $(0, \infty)$ si el jugador fue eliminado ($y_{ij} = 1$), y en $(-\infty, 0)$ si sobrevivió la etapa ($y_{ij} = 0$).

La media teórica de esta variable latente está dictada por el predictor del modelo:

$$\mu_{ij} = \mu_0 + f(t_{(j)}, x_i) \quad (1)$$

Donde μ_0 es un parámetro de centrado base temporal y $f(t_{(j)}, x_i)$ representa la suma continua recolectada de los árboles de BART, los cuales evalúan simultáneamente la etapa del juego $t_{(j)}$ y el vector de características del jugador x_i , compuesto por las variables históricas y relativas al lobby descritas en la sección anterior.

Finalmente, la probabilidad predictiva de eliminación se estima aplicando la función de enlace probit: $p_{ij} = \Phi(\mu_{ij})$, donde $\Phi(\cdot)$ denota la Función de Distribución Acumulada (FDA) de la distribución Normal Estándar.

2.5. Regularización a Priori y Weak Learners

La robustez de BART frente al sobreajuste proviene de distribuciones a priori sumamente restrictivas que obligan a cada árbol a ser un aprendiz débil (weak learner).

- **Estructura del árbol:** La probabilidad de que un nodo interior se divida decae fuertemente respecto a la profundidad d según $\alpha(1+d)^{-\gamma}$. Adoptamos hiperparámetros estándar $\alpha = 0,95$ y $\gamma = 2$ para forzar árboles superficiales.
- **Nodos terminales (Shrinkage):** Las contribuciones predictivas μ_{jk} de cada hoja terminal se modelan como $\mu_{jk} \sim N(0, 2,25/m)$, donde $m = 200$ es el número de árboles. Esto garantiza que las predicciones individuales se contraigan hacia cero.

2.6. Implementación Computacional (MCMC)

Dado que la distribución conjunta posterior no puede resolverse analíticamente, la estimación se realizó por medio del método de Monte Carlo vía Cadenas de Markov (MCMC). La implementación computacional de este proyecto se realizó en el entorno R. El principal esfuerzo algorítmico y de ingeniería de datos consistió en la extracción mediante la API, la estabilización de los historiales (burn-in), y la reestructuración y expansión longitudinal de los datos de supervivencia al formato binario secuencial requerido. Una vez expandida la matriz, el ajuste del modelo aprovechó la arquitectura de variables latentes Probit de Albert y Chib utilizando paquetes especializados de BART binario ya existentes en R para ejecutar el muestreo posterior de la topología de los árboles y sus nodos terminales.

3. Resultados

Como paso previo a la inferencia sobre los registros del torneo de Teamfight Tactics, la evaluación del modelo se dividió en dos etapas: una validación metodológica en escenarios simulados y una prueba empírica piloto sobre datos reales del videojuego.

3.1. Validación Metodológica en Escenarios Simulados

Antes de procesar los registros empíricos, se ejecutó una validación computacional piloto simulando los escenarios controlados propuestos por Sparapani et al. (2016).

En el escenario base de una muestra, diseñado para recuperar una distribución de Weibull verdadera con un porcentaje de censura objetivo del 20 %, las predicciones de la función de supervivencia media posterior de BART trazaron razonablemente bien la curva teórica, superando sistemáticamente al estimador tradicional de Kaplan-Meier en términos de Error Cuadrático Medio (RMSE) y Error Absoluto Medio (MAE).

En el escenario de dos grupos con curvas de supervivencia cruzadas (riesgos no proporcionales), donde los métodos paramétricos tradicionales sufren degradación empírica, el modelo BART modeló exitosamente las trayectorias divergentes, demostrando mejoras consistentes y reduciendo tanto el RMSE como el MAE frente a estimaciones independientes. Las probabilidades de cobertura piloto de los intervalos bayesianos resultaron altas y robustas, confirmando la viabilidad matemática de la arquitectura.

Una vez superada la validación metodológica en escenarios simulados, se procedió a la aplicación del modelo sobre los registros empíricos del torneo de Teamfight Tactics. El objetivo empírico central fue evaluar la capacidad predictiva del algoritmo utilizando únicamente la información histórica de los jugadores y el contexto relativo previo a la partida objetivo.

3.2. Entrenamiento y Selección de Modelos Empíricos

Para la fase de modelado empírico, se estructuró un diseño experimental basado en el entrenamiento y comparación de cuatro especificaciones distintas del modelo BART. Estas variaciones surgieron de la combinación de dos enfoques de procesamiento de datos y dos niveles de dimensionalidad en las covariables:

1. **Datasets de entrenamiento:** Se utilizaron dos conjuntos de datos principales. El primero correspondió al dataset original extraído directamente mediante la API de Riot Games, caracterizado por contener lobbies parciales (aproximadamente 4 jugadores reconstruidos por partida). El segundo fue un dataset enriquecido, en el cual las partidas presentes en la base original fueron expandidas para incluir a un mayor número de oponentes, alcanzando un promedio de 6 o más jugadores reconstruidos por lobby.
2. **Dimensionalidad de las covariables:** Sobre cada uno de los datasets se entrenó una versión con la totalidad de las características construidas (modelo completo, con más de 51 covariables) y una versión con dimensionalidad reducida. Para esta última, se aplicó un Análisis de Componentes Principales (PCA), para identificar las variables con mayor información logrando condensar la misma en un total de 25 variables sin perder la varianza explicativa fundamental de los datos.

Para evaluar rigurosamente el desempeño de estas cuatro variantes sobre los datos de prueba del torneo, se empleó un grupo de métricas conformado por el Integrated Brier Score, Log-loss, la correlación de Spearman, el coeficiente Tau de Kendall y el Índice de Concordancia (C-index).

3.3. Comparación de Modelos sobre el Conjunto de Prueba

La Tabla 1 resume las métricas obtenidas por los cuatro modelos del BART sobre los datos de prueba del torneo, evaluadas en términos de calibración probabilística (Integrated Brier Score y Log-loss medio) y de capacidad discriminativa (C-index, ρ de Spearman y τ de Kendall).

Cuadro 1: Métricas de desempeño predictivo de las cuatro variantes del modelo BART sobre el conjunto de prueba del torneo. Para IBS y Log-loss un valor menor indica mejor calibración; para C-index, ρ y τ un valor mayor indica mejor capacidad discriminativa. El mejor valor por columna se destaca en **negrita**.

Modelo	Dataset / Dim.	IBS ↓	Log-loss ↓	C-index ↑	ρ ↑	τ ↑
<code>model_full</code>	Original / Completo (51+)	0.111	0.353	0.630	0.350	0.345
<code>model_reduced</code>	Original / PCA (25)	0.105	0.337	0.611	0.295	0.278
<code>model_6p_reduced</code>	Enriquecido / PCA (25)	0.099	0.320	0.500	0.039	0.030
<code>model_6p_full</code>	Enriquecido / Completo	0.097	0.315	0.472	-0,043	-0,053

A partir de la revisión de las métricas se puede observar que los modelos entrenados sobre el dataset enriquecido (`model_6p_*`) obtienen los mejores valores de IBS y Log-loss, pero obtienen los peores en discriminación, con un C-index alrededor o por debajo del azar (0.500 y 0.472) y coeficientes de correlación de rangos prácticamente nulos o negativos. En contraste, los modelos entrenados sobre el dataset original recuperan capacidad de ordenamiento, siendo `model_full` el que maximiza simultáneamente los tres estimadores de concordancia ($C = 0,630$, $\rho = 0,350$, $\tau = 0,345$).

Para seleccionar entre las cuatro variantes bajo un criterio único, se normalizó cada métrica al rango $[0, 1]$ orientando todas las escalas en el mismo sentido (cero indica mejor desempeño relativo) y se agregaron en un score global. La Tabla 2 presenta los resultados.

Cuadro 2: Métricas normalizadas y score global de selección. Todas las escalas fueron orientadas de modo que 0 corresponda al mejor desempeño relativo y 1 al peor. El score global agrega las cinco métricas normalizadas.

Modelo	z_{IBS}	$z_{\text{Log-loss}}$	$z_{\text{C-index}}$	z_{ρ}	z_{τ}	Score Global ↓
<code>model_full</code>	0.126	0.117	0.824	0.790	0.793	0.394
<code>model_reduced</code>	0.000	0.000	1.000	1.000	1.000	0.400
<code>model_6p_reduced</code>	0.576	0.581	0.118	0.140	0.168	0.404
<code>model_6p_full</code>	1.000	1.000	0.000	0.000	0.000	0.600

El modelo seleccionado fue `model_full`, entrenado sobre el dataset original y con la totalidad de las covariables construidas (sin reducción por PCA), con un score global de 0.394. Conviene matizar que la diferencia frente a las siguientes dos variantes (`model_reduced` con 0.400 y `model_6p_reduced` con 0.404) es marginal, lo cual evidencia un compromiso real entre calibración y discriminación: los modelos enriquecidos producen probabilidades absolutas mejor calibradas pero pierden la capacidad de ordenar correctamente a los jugadores dentro del lobby. Dado que el objetivo sustantivo del trabajo es predecir el orden de eliminación, las métricas de concordancia recibieron implícitamente mayor peso en la decisión, en línea con el criterio empleado por el score global propuesto.

3.4. Curvas de Supervivencia e Intervalos del Modelo Ganador


Las Figuras 1 y 2 presentan las estimaciones probabilísticas obtenidas por el modelo seleccionado (`model_full`) sobre los nueve lobbies del torneo. La Figura 1 muestra la probabilidad posterior de seguir vivo en función de la ronda para cada jugador reconstruido. La Figura 2 sintetiza la distribución posterior de la ronda de eliminación mediante sus intervalos de credibilidad al 90 % y 95 %, junto con la mediana predicha y la ronda real observada.

4. Discusión


4.1. Desempeño Predictivo sobre Datos de Torneo

Al comparar el rendimiento de las cuatro arquitecturas, el modelo ganador fue el entrenado sobre el dataset original utilizando la totalidad de sus componentes (sin reducción por PCA).


El análisis de este resultado, más allá de lo que muestran los test estadísticos, reveló que la ventaja del modelo original (`model_full`) frente a los modelos enriquecidos (`model_6p`) se debió a la estructura de los datos de evaluación. Debido a las limitaciones inherentes en la extracción de información sobre la totalidad de los participantes del torneo, los lobbies de prueba reconstruidos contenían predominantemente entre 2 y 4 jugadores. En consecuencia, el modelo original, que había sido entrenado bajo condiciones




(a) custom_lobby_01



(b) custom_lobby_04



(c) custom_lobby_05



(d) custom_lobby_06

Figura 1: Curvas de supervivencia posteriores estimadas por el modelo `model_full` sobre los lobbies reconstruidos del torneo con tres o cuatro jugadores. El eje x representa la ronda de juego y el eje y la probabilidad posterior de seguir vivo.




Figura 2: Intervalos predictivos de eliminación al 90 % (azul oscuro) y 95 % (azul claro) estimados por el modelo `model_full`. El punto azul indica la mediana predicha de la ronda de eliminación y el triángulo rojo la ronda real observada.

de escasez de información similar (lobbies parciales), logró generalizar y adaptarse mucho mejor al entorno de evaluación que el modelo enriquecido, el cual esperaba un contexto competitivo más densamente poblado (6 o más jugadores). Asimismo, la versión sin reducción dimensional superó a la versión PCA, sugiriendo que BART es capaz de manejar eficientemente la alta dimensionalidad y extraer valor de las interacciones no lineales entre las más de 40 covariables originales sin sufrir de sobreajuste.

4.2. Análisis de Curvas de Supervivencia e Intervalos de Credibilidad

Las estimaciones probabilísticas emitidas por el modelo ganador demostraron una notable coherencia con la macrodinámica empírica de las partidas. Al analizar visualmente las curvas de supervivencia estimadas por el algoritmo BART, se observó que el modelo logró reflejar de manera precisa el comportamiento escalonado que se espera en una partida de TFT. Específicamente, la función de supervivencia proyecta momentos de estabilización con cambios mínimos, los cuales coinciden empíricamente con las rondas donde no hay enfrentamientos entre jugadores (como las rondas contra el entorno o los carruseles). Asimismo, las curvas consiguen reflejar de forma parcial el orden en que los jugadores son eliminados: los perfiles con caídas tempranas en su probabilidad predictiva correspondieron a los primeros en ser eliminados, mientras que a quienes se les asignó una supervivencia sostenida cayeron en etapas tardías de la partida.

Adicionalmente, el análisis de la incertidumbre predictiva arrojó resultados mixtos.

Por un lado, al contrastar la ronda real de eliminación frente a las estimaciones, se evidenció que la totalidad de las observaciones empíricas cayeron exitosamente dentro de los intervalos de credibilidad generados por las iteraciones MCMC (al 90 % y 95 %). En 16 de los 24 participantes del torneo simulados dentro de sus respectivos lobbies, la distancia de la mediana predicha al dato real fue notablemente cercana, situándose alrededor de las 3 rondas o menos de diferencia, subiendo a 20 de 24 si tomamos una diferencia de 4 o menos rondas.

Por otro lado, se identificó que el intervalo de credibilidad generado es demasiado amplio para ofrecer predicciones con una precisión significativa. Aunque en promedio los errores centrales son moderados, en diversos casos el dato real se halló considerablemente alejado de la media, ubicándose en los límites extremos del intervalo de credibilidad. En la práctica, el intervalo llega a cubrir un rango por encima de 2 o más fases del juego (de 18 a 21 rondas). Esta amplitud extrema compromete la utilidad puntual de la predicción, sugiriendo un alto grado de dispersión en las estimaciones.

4.3. Análisis e Interpretación

El modelado estadístico en competencias de formato *Battle Royale* o suma cero asume una alta interdependencia entre las observaciones. Este trabajo muestra que los errores de predicción individuales pueden volverse condicionalmente intercambiables si se parametriza correctamente el historial competitivo reciente y las ventajas relativas de desempeño frente al lobby disponible.

Un aspecto central sobre los resultados obtenidos es la metodología empleada en el diseño del *pipeline*: el modelo emite sus predicciones utilizando exclusivamente información pre-partida. El hecho de que las curvas de supervivencia logren capturar la estructura de la partida (como las pausas en rondas sin enfrentamientos) y ordenar empíricamente las eliminaciones basándose únicamente en el comportamiento pasado suavizado, valida la solidez de las covariables extraídas.

No obstante, la evaluación empírica nos expone dos limitaciones fundamentales. La primera está relacionada con la recolección del contexto competitivo. Al operar con lobbies parcialmente reconstruidos, las métricas de fortaleza relativa se calcularon frente a subconjuntos de oponentes y no sobre los 8 participantes reales, lo que impidió explotar todo el potencial del modelo enriquecido.

La segunda limitación estructural radica en la capacidad de precisión del algoritmo. Aunque las observaciones caen dentro de los intervalos de credibilidad y existen casos de alta exactitud (con distancias de solo 3 rondas), la amplitud total del intervalo es excesiva. Esta excesiva amplitud indica que, si bien la información histórica pre-partida es robusta para proyectar tendencias relativas y el orden de mérito del lobby, resulta insuficiente para aislar el momento exacto de eliminación. El entorno competitivo de TFT posee una varianza inherente extrema gobernada por elementos observados únicamente durante el transcurso del juego, como la aleatoriedad de la tienda, los emparejamientos y las decisiones tácticas inmediatas, lo que hace imposible reducir la incertidumbre a una ventana predictiva estrecha utilizando solo el pasado de los jugadores.

A pesar de esta dispersión, la principal ventaja teórica del modelado bayesiano se ha evidenciado: BART aprendió naturalmente los riesgos no proporcionales y descubrió la compleja geometría funcional que vincula la experiencia y la consistencia histórica sin

exigir formas funcionales restrictivas.

5. Flujo de Trabajo Reproducible

Para garantizar la trazabilidad del estudio y asegurar que la arquitectura estadística se integre de forma correcta con los datos del entorno competitivo real, se diseñó e implementó un pipeline de procesamiento y modelado estructurado en las siguientes etapas secuenciales:

1. **Resolución de Cuentas y Extracción de Partidas:** Identificación de los jugadores mediante la API de Riot Games (resolviendo Riot IDs a PUUIDs) y recuperación de partidas clasificatorias válidas, aplicando los umbrales de nivel y ronda mínima para asegurar la madurez de la cohorte.
2. **Construcción del Historial por Jugador:** Cálculo dinámico de las métricas de desempeño pasado de cada sujeto. Este paso garantiza estrictamente que, para cualquier fila objetivo, solo se calcule la información disponible cronológicamente antes del inicio de esa partida.
3. **Estabilización mediante Burn-in y Suavizado:** Aplicación de un período inicial de acumulación de datos (10 partidas por jugador) en el cual no se emiten predicciones objetivo, permitiendo estabilizar sus métricas mediante un suavizado empírico-bayesiano que acerca los promedios iniciales a la media global.
4. **Reconstrucción de Lobbies y Contexto Relativo:** Agrupación de los jugadores emparejados en una misma partida para calcular métricas relativas frente a los oponentes disponibles (ventajas de posicionamiento, consistencia, y proporción de victorias).
5. **Expansión Longitudinal:** Transformación de la base de datos de formato transversal a una matriz de supervivencia discreta. Cada partida se despliega en una secuencia binaria temporal indexada por la ronda alcanzada (`last_round`).
6. **Entrenamiento del Modelo BART:** Ajuste del ensamble bayesiano utilizando el enfoque de variables latentes con enlace Probit para relacionar las covariables históricas y del lobby con la probabilidad de supervivencia en cada ronda.
7. **Predicción y Evaluación:** Generación de probabilidades dinámicas y comparación contra las posiciones y rondas reales observadas, aplicando una estrategia de horizonte predictivo fijo para asegurar que la evaluación no sufra de contaminación de datos futuros.

6. Referencias

Referencias

- [1] Sparapani, R. A., Logan, B. R., McCulloch, R. E., & Laud, P. W. (2016). Nonparametric survival analysis using Bayesian Additive Regression Trees (BART). *Statistics in Medicine*, 35(16), 2741–2753.
- [2] Albert, J., & Chib, S. (1993). Bayesian analysis of binary and polychotomous response data. *Journal of the American Statistical Association*, 88(422), 669–679.
- [3] Chipman, H. A., George, E. I., & McCulloch, R. E. (2010). BART: Bayesian Additive Regression Trees. *The Annals of Applied Statistics*, 4(1), 266–298.
- [4] Cox, D. R. (1972). Regression models and life tables. *Journal of the Royal Statistical Society. Series B (Methodological)*, 34(2), 187–220.
- [5] Riot Games. (2023). Riot Games Developer API. Documentación de Teamfight Tactics. URL: <https://developer.riotgames.com/>